




PROIECT MACHINE LEARNING

ANALIZA COMPARATĂ A MODELELOR DE MACHINE LEARNING, ÎN REGRESIE ȘI CLASIFICARE



APRILIE 2026

© Andrei Dumitraș

Cuvânt înainte:

Se cuvine, mai înainte de a păși în cuprinsul acestei lucrări, a rosti câteva gânduri menite să lămurească rostul și noblețea strădaniei ce urmează a fi întreprinsă. Trăim, fără îndoială, într-o epocă în care știința calculului și meșteșugul raționamentului automat capătă o însemnătate tot mai mare, iar puterea de a desprinde ordine din mulțimea faptelor, de a găsi sens în date și de a alcătui judecăți temeinice cu ajutorul mașinilor, se arată a fi una dintre cele mai de preț însușiri ale spiritului modern. Acest proiect nu a fost alcătuit doar spre a încerca dibăcia tehnică a studentului, ci mai ales spre a-l deprinde cu o formă de gândire riguroasă, metodică și luminată, vrednică de cel ce dorește a lucra cu cinste și pricepere în câmpul vast al inteligenței artificiale.

Lucrarea de față își propune să înfățișeze, într-o formă cât mai apropiată de practica adevărată a cercetării și a profesiei, întregul drum al unei întreprinderi de învățare automată: de la cercetarea și înțelegerea datelor, la curățarea și pregătirea lor, de la instruirea și cumpănirea mai multor modele, până la tâlcuirea rezultatelor și înfățișarea lor într-o aplicație interactivă.

Studentului nu i se cere numai să obțină o performanță numerică vrednică de laudă, ci și să-și poată apăra alegerile cu judecată limpede, să compare cu dreaptă măsură metodele întrebuintate, să pătrundă înțelesul predicțiilor făcute de modele și să-și prezinte concluziile într-o formă clară, demnă și convingătoare. Cu alte cuvinte, nu este de ajuns a face mașina să răspundă; trebuie, deopotrivă, a înțelege pentru ce răspunde astfel.

Fie, așadar, această lucrare nu doar un exercițiu școlăresc, ci o veritabilă ucenicie a minții: o încercare în care stăruința, finețea observației, ordinea gândirii și eleganța demonstrației vor cântări tot atât de mult ca izbânda numerică însăși. Iar cel ce va străbate cu seriozitate și bună-cuviință aceste cerințe va dobândi nu doar un proiect împlinit, ci și laudă, glorie, apreciere din partea mai marilor, și o înțelegere mai adâncă a felului în care modelele pot fi chemate să slujească adevărul, discernământul și buna rânduială a cunoașterii.

Conținut

Cuvânt înainte:	2
1. Context general	4
2. Obiective	4
3. Descriere generală a proiectului.....	5
4. Sarcinile proiectului	6
4.1. Definirea problemei	6
4.2. Analiza exploratorie a datelor și pregătirea lor.....	6
4.3. Antrenarea și compararea modelelor de bază	7
4.4. Ajustarea hiperparametrilor	8
4.5. Curbele de învățare	8
4.6. Explicabilitatea și analiza SHAP	8
4.7. Streamlit App	9
5. Criterii de evaluare.....	10
7. Notă de încheiere	11

1. Context general

Acest proiect este gândit astfel încât să simuleze, cât mai fidel, fluxul complet de lucru al unei probleme reale de *machine learning*, oferind studenților prilejul de a parcurge principalele etape ale unui proiect autentic de *data science* și *data engineering*. De la înțelegerea problemei și explorarea datelor, până la preprocesarea acestora, antrenarea și compararea mai multor modele, optimizarea lor prin ajustarea hiperparametrilor, interpretarea comportamentului lor și, în cele din urmă, prezentarea rezultatelor prin intermediul unei aplicații interactive, întregul demers urmărește să ofere o experiență practică și relevantă, precum și o primă deschidere către vastul domeniu al inteligenței artificiale.

În cadrul proiectului vor fi abordate două sarcini de învățare supravegheată: una de clasificare și una de regresie. Pentru fiecare dintre acestea, vor fi explorați și analizați mai mulți algoritmi, astfel încât studenții să poată observa diferențele de comportament, performanță și aplicabilitate dintre diversele metode de modelare.

Scopul proiectului nu constă doar în obținerea unor rezultate predictive cât mai bune, ci și în formarea capacității de a face alegeri metodologice corecte, bine argumentate și clar exprimate. Fiecare decizie de implementare trebuie justificată. Din această perspectivă, proiectul reflectă atât practica reală a utilizării *machine learning*-ului, cât și spiritul activității științifice experimentale, unde valoarea unei soluții nu este dată exclusiv de scorul final al modelului, ci și de calitatea analizei, de rigoarea comparațiilor realizate, de interpretabilitatea rezultatelor și de claritatea cu care sunt formulate și comunicate concluziile.

2. Obiective

Astfel, proiectul de față urmărește deprinderea unui ansamblu de abilități tehnice și practice dovedite și folosite în proiectele de machine learning din industrie dar și din academie. În acest sens, obiectivele principale urmărite prin realizarea acestui proiect sunt următoarele:

- Înțelegerea datelor tabulare și folosirea eficientă a bibliotecii *pandas*.
- Realizarea analizei exploratorii a datelor în scopul obținerii unei imagini de ansamblu asupra structurii și conținutului setului de date.

- Preprocesarea corectă a datelor de intrare, astfel încât acestea să poată fi utilizate de modelele de machine learning.
- Antrenarea și evaluarea mai multor modele diferite de machine learning.
- Efectuarea analizei comparate a performanțelor modelelor, prin metrici și grafice specifice fiecărui model.
- Ajustarea hiperparametrilor pentru cele mai performante modele.
- Interpretarea predicțiilor modelelor și a comportamentului acestora prin folosirea mijloacelor de explicabilitate (*SHAP*).
- Analizarea modului de învățare și generalizare a modelelor prin intermediul curbelor de învățare (*learning curves*).
- Construirea unei aplicații interactive folosind Streamlit prin care rezultatele, modelele și predicțiile să poată fi prezentate într-o formă clară și interactivă – realizându-se totodată și un proiect numa' bun de pus în CV și/sau portofoliul.

3. Descriere generală a proiectului

Proiectul constă în rezolvarea a două sarcini de învățare supravegheată: o problemă de clasificare și o problemă de regresie. Pentru fiecare dintre aceste două probleme, trebuie să se urmeze întreg procesul de învățare automată (*supervised learning*), incluzând analiza exploratorie a datelor (*EDA*), preprocesarea datelor, antrenarea modelului, reglarea hiperparametrilor (*hyperparameters fine tuning*), evaluarea, analiza explicabilității și implementarea modelelor de machine learning prin intermediul unei aplicații web, folosind *Streamlit*. Toate fișierele proiectului, codul de Python, documentația și resursele legate de aplicație (gestionate prin *uv package installer*) trebuie încărcate pe GitHub într-un repository bine structurat.

Proiectul are un pronunțat caracter comparativ. Prin urmare, obiectivul nu este antrenarea unui singur model și prezentarea izolată a rezultatelor sale, ci explorarea, antrenarea și evaluarea mai multor algoritmi pentru fiecare dintre cele două probleme, urmate de o analiză paralelă a comportamentului lor. Modelele trebuie compare atât din punctul de vedere al performanței predictive, cât și din perspectiva comportamentului lor general, folosind metrici adecvate, reprezentări grafice relevante și instrumente de interpretabilitate, precum *SHAP*, acolo unde acestea sunt potrivite.

Se vor realiza astfel două caiete Jupyter Notebook: unul pentru problema de regresie iar altul pentru problema de clasificare, în care se va scrie întreg pipeline-ul de explorare a datelor, de antrenare, de perfecționare a celor mai bune 5 modele și interpretarea lor. Nu se urmărește doar scrierea de cod ci și adăugarea celulelor *Markdown*, având rolul să împodobească codul prin explicații și justificări proprii. Caietele acestea vor sluji drept documentație pentru cele două probleme rezolvate.

4. Sarcinile proiectului

În cele ce urmează sunt prezentate sarcinile proiectului pe care mă aștept să le implementați în mod corect și riguros. Evaluarea va avea în vedere calitatea muncii voastre în ansamblu, atât din perspectiva codului scris, cât și a explicațiilor, justificărilor și interpretărilor pe care le veți oferi pe parcursul realizării proiectului.

4.1. Definirea problemei

Cerințe:

- Descrieți în mod clar problema abordată și explicați ce anume se urmărește a fi rezolvat prin intermediul metodelor de *machine learning*.
- Identificați ce se prezice/clasifică dar și variabilele de intrare/caracteristicile.
- Evidențiați relevanța practică a problemei și explicați de ce construirea unui model de *machine learning* poate fi utilă în acest context.
- Menționați de ce ați ales problema respective.
- Pentru problema de clasificare, menționați în mod explicit clasele existente și semnificația acestora.
- Pentru problema de regresie, precizați variabila de ieșire și, dacă este cazul, semnificația sa practică, unitatea de măsură și intervalul de valori.

Ce se urmărește:

- Înțelegerea problemei și a contextului în care aceasta a apărut.

4.2. Analiza exploratorie a datelor și pregătirea lor

Cerințe:

- Realizarea unui EDA cât mai complet și clar.
- Explorarea structurii și calității datelor.
- Gestionarea valorilor lipsă (dacă există)
- Gestionarea anomaliilor (dacă există)
- Gestionarea diferitelor tipuri de date.
- Analiza grafică, prin diverse grafice.
- Analiza relațiilor dintre variabile.
- Corectarea datelor unde este cazul, și pregătirea acestora pentru modelele ML.

Ce se urmărește:

- Calitatea explicațiilor din urma graficelor folosite.
- Calitatea explicațiilor statistice și a modului prin care acestea descriu datele.

4.3. Antrenarea și compararea modelelor de bază

Cerințe:

- Antrenați modelele de bază pentru fiecare dintre algoritmi propuși în tabelul de mai jos, utilizând setările lor implicite – valorile standard ale hiperparametrilor.
- Împărțiți datele astfel încât 75% din observații să fie utilizate pentru antrenare, iar 25% vor fi rezervate pentru testare și validare.
- Calculați și afișați metricele indicate în al doilea tabel prezentat mai jos, folosind setul de testare și validare.
- Realizați un tabel în *Markdown* în care să prezentați în mod comparativ rezultatele obținute de modelele de bază, evidențiind primii 5 algoritmi care au obținut cele mai bune performanțe.

Ce se urmărește:

- O abordare structurată și clară.
- Rezultate bune unde se întâmplă.
- Folosirea bibliotecii *scikit-learn*.
- Calitatea concluziilor în urma comparării algoritmilor propuși.

Algoritmii propuși:

<i>Clasificare</i>	<i>Regresie</i>
Naïve Bayes	Linear Regression
Logistic Regression	Decision Tree Regressor
Decision Tree	Random Forest Regressor
Random Forest	Support Vector Regressor
Support Vector Machine	K-Nearest Neighbor Regressor
K-Nearest Neighbors	Gaussian Process Regressor
Xtreme Gradient Boost	XGBoost Regressor
Categorical Boost	CatBoost Regressor
Explainable Boosting Machine	Explainable Boosting Regressor

Metrice:

<i>Clasificare</i>	<i>Regresie</i>
Acuratețea	MSE
Precizia	MAE
Recall-ul	RMSE
Scorul F1	R ²
ROC-AUC	
Matricea de confuzie	

4.4. Ajustarea hiperparametrilor

Cerințe:

- Selectați primele 5 modele cele mai performante.
- Folosiți cu atenție *GridSearchCV* și/sau *BayesianSearchCV* pentru căutarea celui mai performant model.
- Atenție la *overfitting*!
- În urma ajustării hiperparametrilor celor mai bune 5 modele, comparați din nou performanța fiecăruia, evidențiind de această dată pe cel mai bun algoritm.

Ce se urmărește:

- Folosirea diferențială a algoritmilor de căutare *GridSearchCV*/*BayesianSearchCV* în funcție de algoritmul perfecționat.
- Alegerea intervalului de valori ale fiecărui hiperparametru

4.5. Curbele de învățare

Cerințe:

- Afișați curbele de învățare pentru cele 5 cele mai bune modele.
- Discutați scenariile de *overfitting* și *underfitting* în urma graficelor afișate.
- Interpretați diferența dintre scorul de antrenare și cel de validare.

Ce se urmărește:

- Calitatea explicațiilor și veridicitatea acestora.

4.6. Explicabilitatea și analiza SHAP

Cerințe:

- Interpretați predicțiile obținute de primele 3 modele perfecționate, utilizând *SHAP*.
- Afișați o explicație *globală* a importanței caracteristicilor, prin intermediul unui *summary plot* și al unui *bar plot*.
- Afișați o explicație *locală* pentru cel puțin una dintre predicții, folosind un *waterfall plot* și un *force plot*.
- Realizați câte un *SHAP scatter plot* pentru 2–3 caracteristici relevante, astfel încât să evidențiați modul în care valorile acestora influențează predicțiile modelului.
- Explicați dacă valorile mari sau mici ale acestor caracteristici tind să împingă predicțiile în sus sau în jos.
- Menționați care sunt cele mai importante 3 caracteristici în procesul de predicție, conform analizei SHAP.
- Pentru cel puțin un exemplu concret, explicați ce variabile au contribuit cel mai mult la rezultatul prezis de model și în ce sens au influențat acesta.

Ce se urmărește:

- Înțelegerea și utilizarea corectă a lui *SHAP*.
- Capacitatea de a analiza atât explicațiile globale, cât și pe cele locale ale predicțiilor.

- Interpretarea relației dintre valorile caracteristicilor și influența acestora asupra rezultatului modelului.
- Formularea unor concluzii clare și argumentate cu privire la comportamentul modelelor perfectionate.
- Folosirea corectă a graficelor relevante.

Resurse utile:

- [SHAP: A Comprehensive Guide to SHapley Additive exPlanations](#) – Geeks4Geeks
- [SHAP](#) – A Data Odyssey, YouTube.

4.7. Streamlit App

Cerințe:

- Creați o aplicație interactivă folosind *Streamlit*, prin intermediul căreia să fie prezentate primele 5 modele antrenate pentru fiecare dintre cele două probleme.
- Realizați câte o pagină separată pentru fiecare sarcină, rezultând astfel un total de 2 pagini: una pentru problema de clasificare și una pentru problema de regresie.
- Includeți, pe fiecare pagină, o scurtă prezentare a setului de date utilizat și a problemei abordate, astfel încât utilizatorul să poată înțelege contextul general al aplicației.
- Afișați cele mai relevante grafice obținute în etapa de analiză exploratorie a datelor.
- Adăugați un mecanism interactiv de selecție – precum un dropdown menu, o listă sau orice altă soluție adecvată – prin care utilizatorul să poată alege unul dintre cele 5 modele pe care dorește să îl testeze.
- Creați o secțiune de introducere a valorilor pentru caracteristicile de intrare (*input features*), precum și o zonă dedicată afișării rezultatului prezis de model.
- Afișați metricile asociate modelului selectat, împreună cu reprezentările grafice relevante pentru evaluarea acestuia.
- Afișați curbele de învățare (*learning curves*) obținute pentru modelul perfecționat selectat.
- Prezentați valorile hiperparametrilor modelului perfecționat.
- Afișați valorile și graficele *SHAP* corespunzătoare predicției generate, astfel încât utilizatorul să poată înțelege ce caracteristici au influențat rezultatul și în ce mod.

Ce se urmărește:

- Capacitatea de a transforma rezultatele tehnice ale proiectului într-o aplicație interactivă, clară și ușor de utilizat.
- Integrarea coerentă a etapelor esențiale ale proiectului într-o interfață unitară: descrierea problemei, explorarea datelor, compararea modelelor, predicția și explicabilitatea.
- Prezentarea într-o formă accesibilă a performanței, comportamentului și interpretabilității modelelor selectate.
- Realizarea unei aplicații cu valoare demonstrativă, practică și prezentabilă, potrivită atât pentru evaluare, cât și pentru portofoliu.
- Calitatea vizuală a paginii web, simțul estetic și așezarea în pagină.

- Interactivitatea cu modelul afișat pe pagină și *user-experience* overall.
- Gestionarea mai multor modele ML într-o formă *user-friendly*.

Resurse utile:

- [Streamlit: The Fastest Way To Build Python Apps?](#) – pixegami, YouTube.
- [Streamlit \(Web Application in Python\)](#) – Data Professor, YouTube playlist.

5. Criterii de evaluare

- Prezentare problemă: 5p
- EDA completă: 20p
- Antrenarea și compararea modelelor de bază: 25p
- Ajustarea hiperparametrilor: 15p
- Curbele de învățare: 10p
- Explicabilitatea modelelor folosind SHAP: 10p
- Streamlit UI: 15p
- Pentru bonus:
 - Eleganță în implementare, structură ordonată a caietelor Jupyter, a codului sursă dar și în *Markdown*.
 - Un user-experience plăcut în aplicația Streamlit.
 - Analiză aprofundată în partea de SHAP – dacă se merge *extramile*.
 - Calitate overall a raportului și a explicațiilor oferite înăuntru.
 - Orice urmă de inovare este binevenită.

7. Notă de încheiere

Ajunși, dară, la capătul acestei lucrări, se cade a privi în urmă cu luare-aminte și a socoti nu doar osteneala depusă, ci și rodul ei cel mai de preț: deprinderea unei gândiri rânduite, cercetătoare și temeinice. Căci dacă, pe parcursul acestor pagini, s-au cercetat date, s-au cumpănit modele, s-au măsurat performanțe și s-au tâlcuit predicții, rostul cel mai înalt al unei asemenea strădanii nu se află numai în izbânda tehnică, ci în formarea acelei judecăți limpezi care știe a deosebi aparența de substanță, întâmplarea de regulă și încercarea pripită de cercetarea bine întemeiată. În această privință, adevărata câștigare nu este doar aceea a unui model mai iscusit, ci a unei minți mai bine deprinse să întrebe, să cerceteze și să înțeleagă.

Să nu se creadă, însă, că învățătura se sfârșește odată cu încheierea acestui proiect. Dimpotrivă, ceea ce s-a adunat aici nu este decât începutul unei ucenicii mai largi, al unei călătorii intelectuale în care fiecare răspuns bine dobândit naște alte întrebări, iar fiecare concluzie cinstit trasă deschide o nouă poartă către înțelegere. Știința învățării automate, asemenea multor altor ramuri nobile ale cunoașterii, nu se lasă stăpânită de cel grăbit ori mulțumit prea lesne cu sine, ci își dezvăluie tainele acelor care lucrează cu răbdare, cu rigoare și cu o neostoită dorință de luminare.

Rămâne, așadar, ca toate cele deprinse în această lucrare — cercetarea atentă a datelor, alegerea cumpănită a metodelor, compararea dreaptă a rezultatelor, tâlcuirea lor cu ajutorul explicațiilor și înfățișarea lor limpede înaintea celorlalți — să nu fie privite ca îndatoriri trecătoare, ci ca temelii trainice ale unei bune formări. Iar dacă aceste pagini au izbutit să sădească în mintea celui studios mai multă rânduială, mai mult discernământ și o mai aleasă înțelegere a felului în care rațiunea omenească poate povățui puterea mașinilor, atunci lucrarea de față nu și-a împlinit rostul în zadar, ci cu cinste și bună cuviință.